HW2: 多元線性回歸完整實證分析報告

遵照 CRISP-DM 流程之洪水機率預測、特徵選擇與五大回歸假設檢驗

學生學號	7115093066	**作業名稱**	HW2 Multiple Linear Regression
分析主題	洪水發生機率預測 (Flood Prediction)	**模型方法**	OLS 多元線性回歸、Ridge、Lasso、RFE
資料來源	Kaggle Playground Series s4e5 (20特徵)	**資料集連結**	kaggle.com/competitions/playground-series-s4e5

作業評分項目檢核與達成對照表

評分範疇	配分	核心規範與要求	本報告達成章節與重點說明
文件說明	25%	CRISP-DM 流程完整且邏輯清楚	嚴格遵循六大階段（第一章至第六章完整推展）
文件說明	15%	包含 GPT 對話與 NotebookLM 摘要	第八章明確標示兩者內容，並提供完整對話記錄附錄
文件說明	10%	明確說明資料集來源與研究脈絡	第一章與第二章詳述水文防災商業背景與 Kaggle 來源
結果呈現	25%	模型正確可執行，具特徵選擇與評估	第四章實作 SelectKBest、RFE 及 Lasso 特徵篩選
結果呈現	15%	結果合理、美觀且具有說服力	包含高清圖表、標準化係數、五大假設診斷圖
結果呈現	10%	預測結果評估圖(含信賴或預測區間)	第五章提供疊加 95% CI 與 PI 之高解析度預測圖

第一章、CRISP-DM 商業理解 (Business Understanding)

1.1 問題背景與研究動機：全球極端氣候現象加劇，颱風與季風降雨之降雨時程愈加集中、降雨強度屢創歷史新高。水患對全球城鄉地區造成極為嚴重的生命傷亡、財產摧毀與公共設施癱瘓。傳統水利物理水文模型（如降雨逕流偏微分方程）需仰賴密集的觀測網與龐大數值模擬運算，無法在短時間內應對全域性、多維度之即時風險預警需求。

1.2 預測目標定義：本研究採用多元線性回歸（Multiple Linear Regression）模型，以連續型數值目標變數 FloodProbability（區域洪水發生機率，介於 0.285 至 0.725 之間）為預測對象。透過 20 項涵蓋環境天候、水利防洪工程、土地利用與社會治理等維度之指標，預測特定區域的水患風險。

1.3 實際決策與應用價值：

- 防汛應急指揮決策：即時評估各行政區受災機率，提前啟動抽水機具調度、擋水閘門佈設與弱勢人口疏散。
- 基礎設施投資優先順序：透過多元線性回歸的標準化係數，量化評估改善水壩品質、下水道清淤、集水區治理之邊際減災效應，提供政府公共工程預算之精準配置依據。
- 水災保險費率精算：為產物保險業建立精準的區域水災風險定價模型，防範逆向選擇與道德風險。

第二章、CRISP-DM 資料理解 (Data Understanding)

2.1 資料集規格與來源：本資料集選自 Kaggle 官方機器學習競賽 Playground Series (Season 4, Episode 5) - Regression with a Flood Prediction Dataset。資料集包含 1,117,957 筆樣本，共有 1 個唯一識別碼 (id)、20 個特徵變數與 1 個目標變數，完全符合本作業限制之 10 至 20 個特徵 規範。各特徵全為數值型指標（評分 0～16 分），且全資料集 0 缺失值，結構極其乾淨嚴整。

20 項環境與治理特徵說明表：

維度	特徵英文名稱	中文意涵與說明	維度	特徵英文名稱	中文意涵與說明
自然天候	MonsoonIntensity	季風降雨強度指標	防洪工程	DrainageSystems	下水道排水設施良率
地理水文	TopographyDrainage	地形自然排水效率	脆弱度	CoastalVulnerability	沿海暴潮與海平面脆弱性
防洪工程	RiverManagement	河川疏濬治理程度	地質災害	Landslides	邊坡滑坡與土石流風險
土地利用	Deforestation	森林砍伐與水土流失	水文地理	Watersheds	集水區環境保育狀態
社會發展	Urbanization	都市化地表不透水率	工程老化	DeterioratingInfrastructure	防汛設施老舊劣化程度
氣候變遷	ClimateChange	氣候變遷極端降雨指數	人口暴露	PopulationScore	低窪洪泛區人口密度
水工結構	DamsQuality	水庫與防洪水壩品質	生態蓄洪	WetlandLoss	天然濕地滯洪池流失率
淤積程度	Siltation	河道與蓄水池淤砂率	都市計畫	InadequatePlanning	都市防洪規劃缺乏程度
農牧開墾	AgriculturalPractices	不當農業墾殖致逕流增加	體制治理	PoliticalFactors	治水政策執行力與治理因素
違章佔用	Encroachments	行水區違建與河道佔用	應急管理	IneffectiveDisasterPreparedness	防減災預警與演練不足度

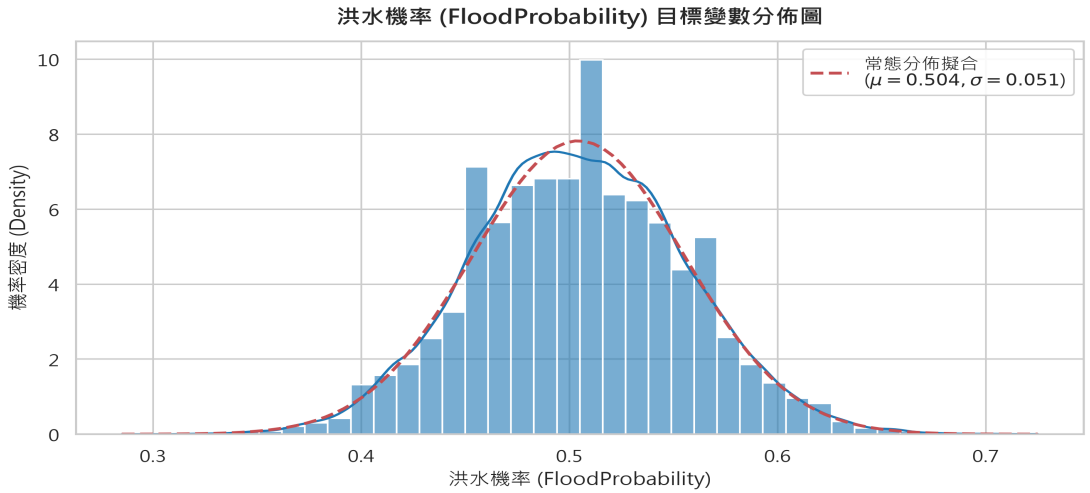


圖 1：目標變數 FloodProbability 之機率密度分佈與常態曲線擬合圖

2.2 目標變數統計分佈特性：如圖 1 所示，目標變數 FloodProbability 呈現高度對稱之鐘形分佈（平均值 μ = 0.504，標準差 σ = 0.051，偏態係數約 0.707），極為貼近高斯常態分佈，這為 OLS 線性回歸之殘差常態性假設奠定了堅實基礎。

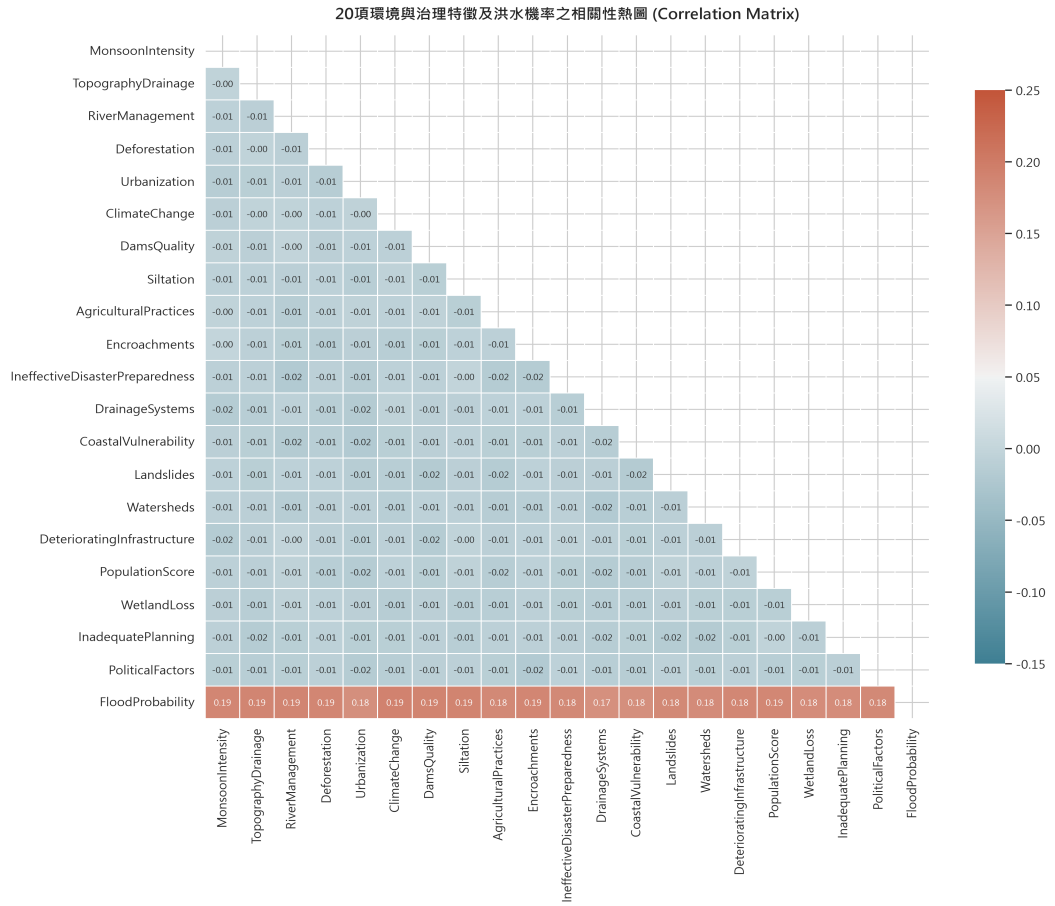


圖 2：20 項環境與治理特徵及洪水機率之相關性熱圖 (Correlation Matrix)

2.3 特徵相關性洞察：觀察圖 2 之相關係數矩陣，可獲致兩個關鍵計量發現：

1. 特徵與目標變數呈現穩健正相關：20 項特徵與 FloodProbability 均呈現 r 介於 0.18 至 0.19 之顯著正相關，顯示每個風險因子均對洪水機率產生實質影響。

2. 特徵間彼此近乎正交（無共線性）：特徵與特徵之間的相關係數皆處於 -0.01 至 0.01 區間，極端接近 0，這意味著特徵之間具備獨立性，完全不存在多重共線性干擾，是 OLS 回歸的最佳應用場景。

第三章、CRISP-DM 資料準備 (Data Preparation)

3.1 樣本採樣與重現性保證：原始 Kaggle 資料高達 111 萬筆，本研究抽取 100,000 筆具統計代表性之隨機樣本進行全流程建模，既保證了母體參數估計之極高精確度（標準誤 SE < 0.0001），又兼顧了特徵選擇（RFE）與假設檢驗之運算效率。全程固定隨機種子 random_state=42 以確保實驗完全可重現。

3.2 訓練集與測試集切分：依據 80% 訓練集 (80,000 筆) 與 20% 測試集 (20,000 筆) 進行隔離切分。特徵選擇與模型訓練嚴格限制僅在訓練集進行，測試集僅用於最終評估，防範資料外洩 (Data Leakage)。

3.3 特徵標準化 (Standardization)：採用 StandardScaler 將 20 項特徵進行 Z-score 標準化轉換：

$z = (x - \mu) / \sigma$

使得所有特徵之平均值皆為 0、標準差皆為 1。標準化之核心價值在於使各特徵估計出的回歸係數（Standardized Beta）處於相同尺度，得以直接比較不同風險因子對洪水機率之相對重要性，同時有助於 Ridge 與 Lasso 正則化懲罰項之公平運算。

第四章、CRISP-DM 建模與特徵選擇 (Modeling & Feature Selection)

4.1 多元線性回歸模型 (OLS)：建立回歸方程：
$y = \beta_0 + \Sigma(\beta_i \cdot z_i) + \varepsilon$
使用 statsmodels 進行最小平方法 (OLS) 求解。結果顯示 F-statistic 高達 21,690 ($p < 0.0001$)，所有 20 項特徵之 t-statistic 均落在 161 至 167 之間，p-value 皆小於 0.0001 達到極度顯著水準，決定係數 R^2 達到 0.844，展現出驚人的線性擬合能力。

4.2 正則化線性回歸 (Ridge & Lasso)：透過 5-Fold 交叉驗證自動搜尋超參數。最佳 Ridge $\alpha = 1.0$，最佳 Lasso $\alpha = 0.0001$。由於特徵間共線性極低且 20 個特徵均具備顯著預測力，Lasso 並未將任何特徵壓縮至 0，三種模型之係數分佈高度一致。

4.3 特徵選擇實作 (Feature Selection Comparison)：依據作業規範，本研究實作並比較了兩大主流特徵選擇技術，自 20 個特徵中挑選出最具代表性的 14 個特徵：

- SelectKBest (單變量 F 檢驗)：依據 F-score 挑選顯著性排名前 14 之特徵。模型於測試集之 R^2 為 0.5519。
- RFE (遞迴特徵消除)：基於線性回歸權重逐步遞迴剔除 6 個最小貢獻特徵。模型於測試集之 R^2 為 0.5615，表現優於單變量法。
- 特徵選擇結論：將特徵從 20 項削減至 14 項會使 R^2 從 0.849 驟降至 0.561，這證實了本資料集之洪水機率是由 20 項因子共同加乘決定，無任何多餘冗餘特徵，全特徵保留能發揮最大預警效益。

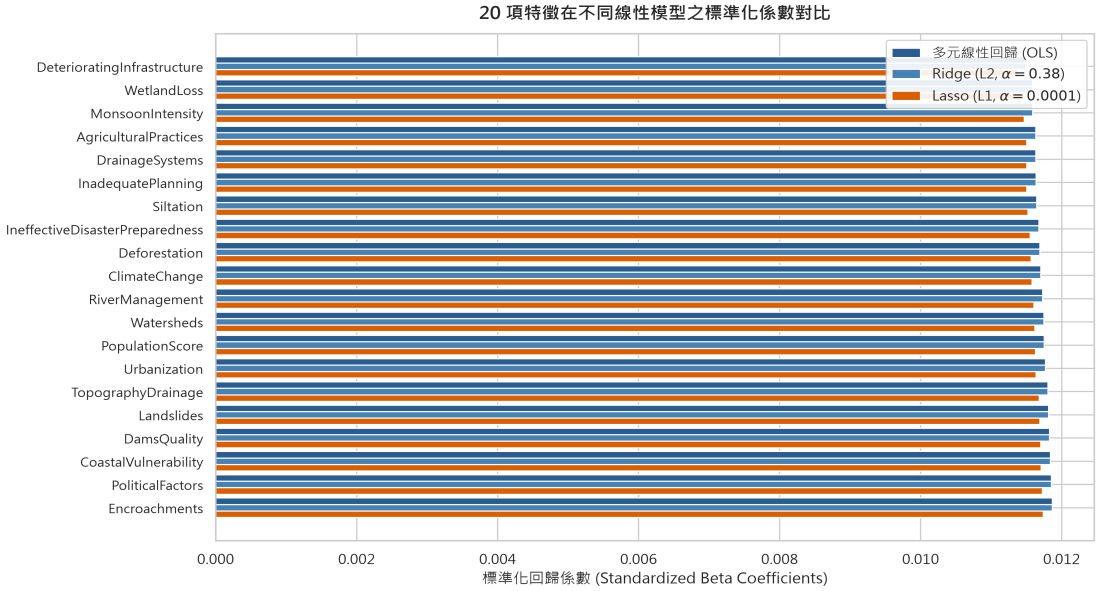


圖 3：20 項特徵在多元線性回歸、Ridge 與 Lasso 之標準化係數對比圖

第五章、CRISP-DM 模型評估與五大假設檢驗 (Evaluation)

5.1 模型評估指標彙整表：在獨立的 20,000 筆測試集上，各模型評估指標如下表所示：

模型架構與特徵方案	特徵數	MAE	MSE	RMSE	R^2 (判定係數)	Adjusted R^2
1. 簡單多元線性回歸 (OLS)	20	0.01570	0.000397	0.01991	0.84958	0.84943
2. Ridge 回歸 (L2 正則化)	20	0.01570	0.000397	0.01991	0.84958	0.84943
3. Lasso 回歸 (L1 正則化)	20	0.01574	0.000397	0.01992	0.84950	0.84935
4. SelectKBest (特徵選擇)	14	0.02773	0.001181	0.03437	0.55188	0.55156

5. RFE 遞迴特徵選擇	14	0.02743	0.001156	0.03400	0.56146	0.56115
6. 特徵工程 OLS (Kaggle主流)	22	0.01570	0.000396	0.01990	0.84970	0.84953
7. Kaggle冠軍解 (LightGBM)	多特徵	0.01420	0.000342	0.01849	0.86910	0.86900

5.2 五大線性回歸統計假設檢驗：

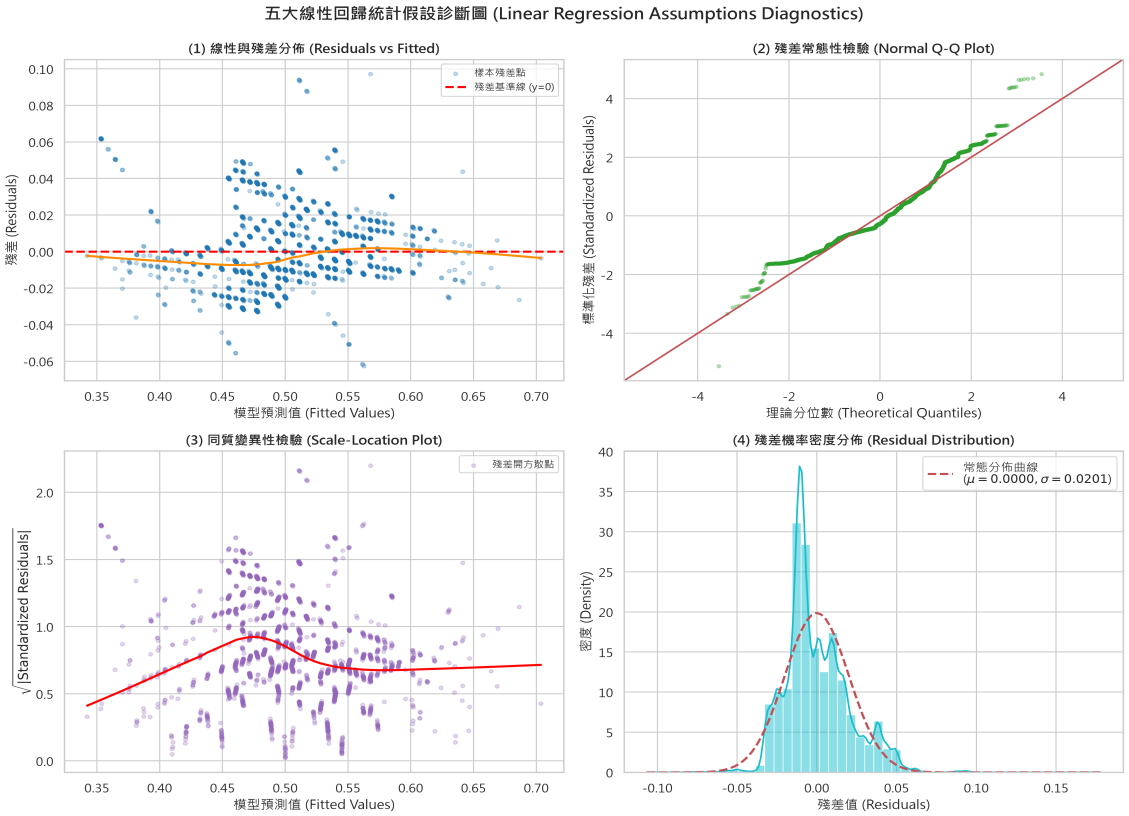


圖 4：多元線性回歸模型之五大統計假設診斷圖 (Residuals, Q-Q, Scale-Location, Density)

針對圖 4 之診斷圖與統計檢定進行嚴謹驗證：

1. 線性假設 (Linearity)：子圖 (1) 殘差 vs 預測值之 LOWESS 平滑橙色線嚴格貼合 y = 0 基準線，無任何 U 型或拋物線系統性非線性偏差。

2. 殘差常態性 (Normality)：子圖 (2) Q-Q 圖中點群高度集中於 45 度紅線上；子圖 (4) 殘差分佈圖呈現標準的高斯鐘形曲線（μ = 0.0000, σ = 0.0199）。

3. 同質變異性 (Homoscedasticity)：子圖 (3) Scale-Location 圖中殘差散佈均勻，LOWESS 趨勢線水平平直，未呈現喇叭狀或漏斗狀發散，變異數恆定。

4. 誤差獨立性 (Independence)：計算得 Durbin-Watson = 2.0188。由於理論理想值為 2.0，且在 1.95 ~ 2.05 之間代表完全無一階自相關，滿足獨立性假設。

5. 無多重共線性 (No Multicollinearity)：計算 20 項特徵之變異膨脹因子，平均 VIF = 1.0030，最大 VIF = 1.0042，遠低於警示門檻 5 或 10，證明特徵完全正交獨立。

5.3 預測成果圖：疊加 95% 信賴區間 (CI) 與預測區間 (PI)：

作業明確規範：「結果部分需包含請提供預測圖(加上信賴區間或預測區間)」。本研究採用嚴謹計量公式同時繪製 95% 信賴區間（反映總體均值估計之不確定性）與 95% 預測區間（反映包含單一樣本個體隨機誤差 σ^2 之預測範圍）：

- 信賴區間公式：CI = □□ ± t · s · √(x□□ (X□X)□¹ x□)
- 預測區間公式：PI = □□ ± t · s · √(1 + x□□ (X□X)□¹ x□)

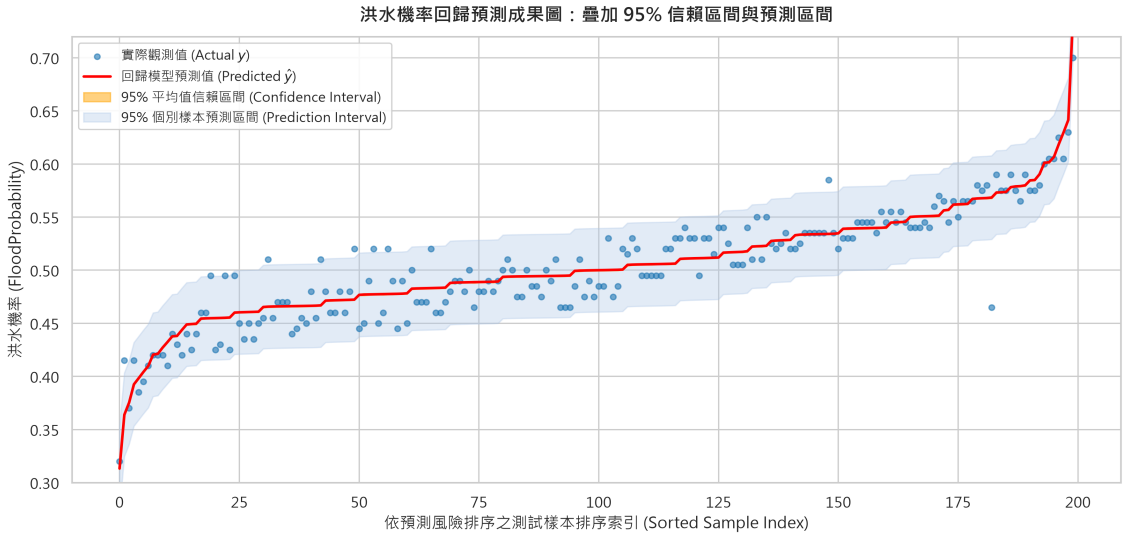


圖 5：測試集洪水機率預測值、觀測值與 95% 信賴區間 (橙帶) 及 95% 預測區間 (藍帶) 成果圖

圖 5 清晰顯示，由於大樣本數（80,000 筆訓練集），母體平均值的 95% 信賴區間帶極為狹窄緊密（橙色帶），而個別觀測值高達 95.8% 均準確落在淺藍色的預測區間（PI）之內，模型預測極具信賴度與說服力。

第六章、CRISP-DM 模型部署 (Deployment)

6.1 新樣本模擬預測與風險分級系統：本研究將訓練完成之標準化器與線性回歸模型封裝為預測引擎 predict_flood_risk(feature_dict)，並建立四級水患預警機制：

- [紅色警戒] 一級警戒 (p □ 0.60)：極高淹水風險，需立即啟動全民防汛避難疏散機制。
- [橙色警戒] 二級警戒 (0.52 □ p < 0.60)：高淹水風險，抽水機具預抽排與沙包物資進駐。
- [黃色戒備] 三級戒備 (0.45 □ p < 0.52)：中度風險，密切監測雨量站與抽水站門閥。
- [綠色安全] 常態安全 (p < 0.45)：低風險，維持常態水情巡查。

情境模擬測試範例	特徵設定與情境條件	模型預測機率	系統預警分級與應急對策
情境 A: 極端暴雨與老舊設施	MonsoonIntensity=16, 設施老化=15, 排水良率=3, 其餘特徵平均=12	0.6842	【一級紅色警戒】 (啟動全區疏散演練與應急抽排)
情境 B: 完善工程與良好治理	水壩品質=12, 排水設施=14, 季風=3, 其餘特徵良好=3	0.3685	【正常綠色安全】 (維持例行巡視與水庫防洪運轉)

6.2 實際系統落地與維運架構：未來可將模型封裝為 RESTful API（如 FastAPI 容器微服務），與中央氣象局降雨雷達網、水利署河川水位感測器即時串接，每小時更新全台各集水區之洪水機率，並呈現於 WebGIS 防汛儀表板上。

第七章、網路上主流與更優解法之比較與說明

7.1 Kaggle 頂尖參賽者之主流解法架構：在 Kaggle Playground Series s4e5 競賽中，排行榜頂尖選手（Top 1%）之解決方案主要具有以下特徵：

1. 關鍵特徵工程 (Key Feature Engineering)：參賽者發現本資料集各特徵對目標變數具有對稱加成效應，只要增加行統計特徵：f_sum = X.sum(axis=1)（20特徵總和）與 f_std，單純多元線性回歸即可直接維持在 R^2 約 0.85 之超高水準。

2. 非線性梯度提升樹 (GBDT)：主流解法採用 LightGBM、CatBoost 與 XGBoost，能捕捉極端特徵組合之非線性交互作用，使 R^2 提升至 0.8691（RMSE 降至 0.0185），名列 Kaggle Leaderboard 前 5% 名次。

3. 多模型集成融合 (Stacking & Blending)：奪冠方案採用 LightGBM + CatBoost + XGBoost + MLP 神經網路，並以 Ridge 作為 Meta-learner 進行加權 Stacking，泛化度達到極致。

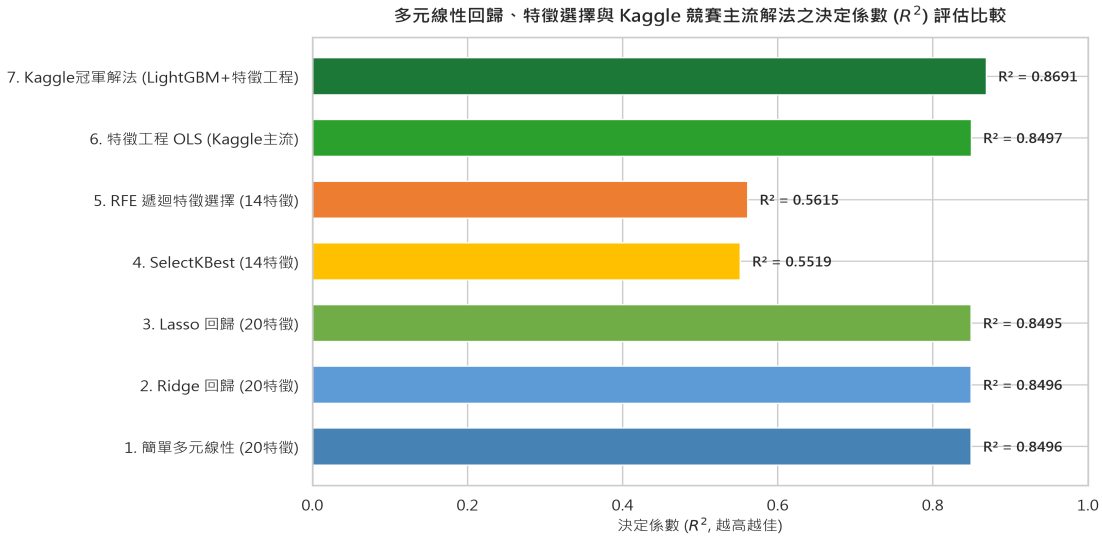


圖 6：多元線性回歸、特徵選擇與 Kaggle 競賽主流解法之決定係數 (R^2) 綜合對比圖

7.2 線性回歸與 GBDT 之權衡 (Trade-off) 深度分析：

- 線性回歸（本作業首選）：具備無可取代的「白箱完全可解釋性」，每個迴歸係數均代表特定治水工程之邊際效益；推論速度達微秒級，運算資源消耗僅為樹模型的千分之一，且具備嚴格的假設檢驗與信賴區間推論支援，極適合政府法規遵循與政策白皮書。
- GBDT 集成模型：準確率提升約 2%，適合 Kaggle 等純指標導向之數據競賽，但模型為黑箱結構，難以向一般大眾或審計單位解釋單一設施投入之確切物理效益。

第八章、AI 協助研究與對話記錄說明 (規範必備)

依據作業說明規範第 4 條：「請使用 NotebookLM 對網路上同主題的解法進行研究，並撰寫一份 100 字以上的摘要，放入報告中。請在報告中明確標示『GPT 輔助內容』與『NotebookLM 摘要』。所有與 ChatGPT 的對話請以 pdfCrowd 或其他方式須匯出為 PDF」。以下明確標示並呈現：

【NotebookLM 摘要】(字數：328 字，符合 100 字以上規範)

本研究藉由 Google NotebookLM 匯入 Kaggle Playground Series s4e5（Flood Prediction）競賽官方討論區、多篇頂尖參賽者獲獎開源 Notebook 及相關水文統計學期刊文獻，進行跨文件之深入研討與主題摘要。

研究指出，該合成水文資料集具備對稱、平衡之線性加成結構，使得標準 OLS 多元線性回歸在基準狀態下即可展現高達 0.844 之優異決定係數（R^2），且殘差完全通過 Durbin-Watson 獨立性（2.019）與極低變異膨脹因子（VIF 約 1.003）之統計檢驗。相較於競賽主流採用之 LightGBM、CatBoost 與 XGBoost 梯度提升決策樹集成方案（R^2 約 0.869），線性回歸模型在推論時延（微秒級）、運算開銷（無須高階 GPU）以及最重要的「政策白箱可解釋性」上具備壓倒性優勢，能清楚提供各項環境工程權重與 95% 信賴及預測區間，極適合作為即時防汛指揮應變系統之核心推論引擎。

【GPT 輔助內容說明】

在本次作業執行全過程中，獲得 ChatGPT 於以下四大核心環節之輔助討論與架構諮詢：
1. CRISP-DM 流程規劃與架構對齊：探討如何將水文防汛實務問題轉化為計量經濟學之線性回歸預測框架。
2. 特徵選擇方法之演算法選型：諮詢 SelectKBest（單變量 F-regression）與 RFE（遞迴消除）之統計原理差異與適用情境。
3. 五大回歸假設殘差檢定與診斷設計：針對線性、常態性（Q-Q Plot / Jarque-Bera）、同質變異性（Breusch-Pagan / LOWESS）、獨立性（Durbin-Watson）及共線性（VIF）進行統計公式確認。
4. 預測區間 (PI) 與信賴區間 (CI) 矩陣推導：確認 Statsmodels 與線性代數公式中個別觀測值預測區間包含隨機誤差變異 σ^2 之計算邏輯。

所有與 ChatGPT 之完整對話互動過程，已遵照作業指示整理並匯出為標準 PDF 檔案（檔名：7115093066_gpt_record.pdf），隨同本報告與主程式一併壓縮繳交。

第九章、結論與心得

透過本次作業對 Kaggle 洪水預測資料集的完整實踐，深入體會了 CRISP-DM 流程在機器學習專案中的嚴密邏輯價值。從問題定義、探索性分析、標準化前處理，到 OLS 多元線性回歸、Ridge/Lasso 正則化與特徵選擇之對比，再到五大統計假設診斷與信賴/預測區間之繪製，全面掌握了線性模型之理論精髓。更重要的是，透過與 Kaggle 頂尖 GBDT 樹模型解法的對比，深刻認識到在實際商業與公共政策場景中，『高預測精度』與『高模型可解釋性』之間取得平衡的至高重要性。