# HW2: Multiple Linear regression

**類型**
個人作業

**開放繳交**
2025-10-15 00:00

**繳交期限**
**2026-10-28**

**已繳交**
22人

**允許遲交**
是

**成績比重**
10%

**評分方式**
直接打分數

**說明**
**一、作業目標：**
本次作業延伸自 HW1，目標是讓同學能夠以實際資料集進行「多元線性回歸 (Multiple Linear Regression)」的完整分析，並遵循 CRISP-DM 流程完成從資料理解、建模到評估的全過程。

**二、作業內容：**
1. 資料來源
 至 Kaggle 選擇一個具有 10 至 20 個特徵 (features) 的公開資料集。
 類型不限（可為房價預測、醫療、車輛效能等主題）。
 請明確標示資料集來源與連結。
2. 分析任務
 使用線性回歸 (Linear Regression) 模型進行預測。
 可嘗試單純線性回歸、多元線性回歸或 Auto Regression。
 必須執行 **特徵選擇 (Feature Selection)** 與 **模型評估 (Model Evaluation)**。
 結果部分需包含請提供預測圖(加上信賴區間或預測區間)
3. CRISP-DM 流程說明
  Business Understanding
  Data Understanding
  Data Preparation
  Modeling
  Evaluation
  Deployment

4. AI協助要求
 所有與 ChatGPT 的對話請以 pdfCrowd 或其他方式須**匯出為 PDF**
 請**使用 NotebookLM** 對網路上同主題的解法進行研究，並撰寫一份 100 字以上的摘要，放入報告中。
 請在報告中明確標示「GPT 輔助內容」與「NotebookLM 摘要」
5. 繳交內容
 主程式：7114056XXX_hw2.py/.ipynb
 報告檔： PDF，需包含以下內容：
  按照 CRISP-DM 說明的分析流程
  GPT 對話過程（pdfCrowd 匯出）
  NotebookLM 研究摘要

網路上主流或更優解法之比較與說明

以上檔案與資料夾**請壓縮為學號命名的一個zip**（例如 7114056XXX_hw2.zip）上傳。

(optional) 若上傳至 GitHub，或是以colab撰寫，需提供連結，並在 README.md 中整理流程與成果。

**三、評分標準**

**文件說明（50%）**

CRISP-DM 流程完整且邏輯清楚（25%）

包含 GPT 對話與 NotebookLM 摘要（15%）

有明確說明資料集來源與研究脈絡（10%）

**結果呈現（50%）**

模型正確可執行，具特徵選擇與評估（25%）

結果合理、美觀且具有說服力（15%）

呈現出Kaggle名次(若有)/預測結果評估(預測圖、評估指標)（10%）

list kaggle multiple linear regression problems , choose features > 13,
< 40

## Kaggle Multiple Linear Regression Problems (14–39 Features)

你希望找適合 **Multiple Linear Regression（多元線性回歸）** 的 Kaggle 題目，條件為：

$$13 < \text{Number of Features} < 40$$

也就是 **14–39 個輸入特徵**，不包含 Target（預測目標）。

建議優先選擇連續數值預測（Regression）、可使用 `sklearn.LinearRegression` 、適合進行 Feature Selection、MSE、RMSE、$R^2$ 與五大回歸假設檢驗的資料集。

特別注意：Kaggle 上常見的 House Prices — Advanced Regression Techniques 有 **79 個原始特徵**，不符合你的原始特徵數限制，但可以透過特徵選擇建立 14–39 特徵的練習版本。

k

Kaggle

+1

### Recommended Kaggle Regression Problems

以下區分「原始特徵符合條件」與「需要 Feature Selection 才符合條件」。

| # | Kaggle Problem | Features | Target | Suitability |
|---|---|---|---|---|
| 1 | Predict the Flood | 20 | FloodProbability | Excellent |
| 2 | Flood Prediction Dataset | 20 | FloodProbability | Excellent |
| 3 | Istanbul Apartment Prices 2026 | 29 or fewer* | Price | Good |
| 4 | Swiss Housing Price Prediction | 30 | House price | Good; restricted access |

| | | | | |
|---|---|---|---|---|
| 5 | Human–AI Interaction | 20 | Trust score | Excellent; synthetic |
| 6 | House Prices — Advanced Regression | 79 → select 20–30 | SalePrice | Excellent for feature selection |

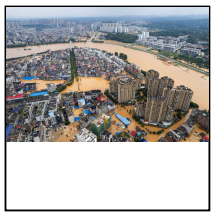
*Istanbul 資料集描述為 30 欄，包含價格等欄位；精確輸入特徵數需檢查 CSV。上述資料集的特徵數以來源描述為準，類別編碼後可能增加。

k

Kaggle

+5

## My Top 3 for Teaching



### 1. Predict the Flood

20 numerical features, continuous target. Best for teaching OLS, MSE, $R^2$, residual analysis and regression assumptions.



### 2. Istanbul Apartment Prices

Suitable for categorical encoding, feature selection, and housing-price regression. Check the dataset columns before modeling.



### 3. Human–AI Interaction

20 original features, 10,100 samples. Useful for studying coefficients, categorical features and multicollinearity.

## Suggested Assignment: CRISP-DM + Feature Selection

For any selected dataset, students can complete:

1. **Business Understanding:** Define the continuous prediction target.
2. **Data Understanding:** Verify sample size, feature count, missing values and correlations.
3. **Data Preparation:** Train/test split, missing-value handling and categorical encoding.
4. **Modeling:** Train `LinearRegression`, Ridge and Lasso.

5. **Evaluation:** Compare MAE, MSE, RMSE, $R^2$ and Adjusted $R^2$; check the five regression assumptions.
6. **Deployment:** Predict new samples and explain the model.

For Feature Selection, compare **SelectKBest, RFE, Sequential Feature Selection, Lasso and permutation importance**, selecting 14, 20, 25 or 30 features using training data only.

**My first choice is Predict the Flood**, because its 20 numerical features meet your constraint directly and avoid the extra complexity of categorical encoding.

交作業

© Copyright since 2020 by National Chung Hsing University.
All rights reserved.
● 本站由 教學資源暨發展中心 管理●

線上： 463 人