HW2: Multiple Linear regression

類型
個人作業

開放繳交
2025-10-15 00:00

繳交期限
2026-10-28

已繳交
72人

允許遲交
是

成績比重
10%

評分方式
直接打分數

說明
========加分 ==============
加總分 1分:
1. 有下拉視窗呈現兩種problem
加總分2分
1. 可任意輸入 Dataset (such as https://raw.githubusercontent.com/Avik-Jain/100-Days-Of-ML-Code/master/datasets/50_Startups.csv)
======== ======== ========

一、作業目標：
本次作業延伸自 HW1，目標是讓同學能夠以實際資料集進行「多元線性回歸 (Multiple Linear Regression)」的完整分析，並遵循 CRISP-DM 流程完成從資料理解、建模到評估的全過程。

二、作業內容：
1. 資料來源
至 Kaggle 選擇一個具有>13 個特徵 (features) 的公開資料集。
類型不限（可為房價預測、醫療、車輛效能等主題）。
請明確標示資料集來源與連結。
2. 分析任務
使用線性回歸 (Linear Regression) 模型進行預測。
可嘗試單純線性回歸、多元線性回歸或 Auto Regression。
必須執行 **特徵選擇 (Feature Selection)** 與 **模型評估 (Model Evaluation)**。
結果部分需包含請提供預測圖(加上信賴區間或預測區間)
3. CRISP-DM 流程說明
Business Understanding
Data Understanding
Data Preparation
Modeling
Evaluation
Deployment

4. AI協助要求

所有與 ChatGPT 的對話請以 pdfCrowd 或其他方式須**匯出為 PDF**
請**使用 NotebookLM** 對網路上同主題的解法進行研究，並撰寫一份 100 字以上的摘要，放入報告中。
請在報告中明確標示「GPT 輔助內容」與「NotebookLM 摘要」
5. 繳交內容
主要繳交: 跟 DIC2 一樣github and web
optional :對話內容, 資訊圖表

==========

三、評分標準

主要繳交: 跟 DIC2 一樣github and web
optional :對話內容, 資訊圖表 , 報告書
不夠事後可再補 1次

list kaggle multiple linear regression problems , choose features > 13,
< 40

Kaggle Multiple Linear Regression Problems (14–39 Features)

你希望找適合 **Multiple Linear Regression（多元線性回歸）** 的 Kaggle 題目，條件為：

$$13 < \text{Number of Features} < 40$$

也就是 **14–39 個輸入特徵**，不包含 Target（預測目標）。

建議優先選擇連續數值預測（Regression）、可使用 `sklearn.LinearRegression` 、適合進行 Feature Selection、MSE、RMSE、R^2 與五大回歸假設檢驗的資料集。

特別注意：Kaggle 上常見的 House Prices — Advanced Regression Techniques 有 **79 個原始特徵**，不符合你的原始特徵數限制，但可以透過特徵選擇建立 14–39 特徵的練習版本。

Kaggle

+1

Recommended Kaggle Regression Problems

以下區分「原始特徵符合條件」與「需要 Feature Selection 才符合條件」。

#	Kaggle Problem	Features	Target	Suitability
1	Predict the Flood	20	FloodProbability	Excellent
2	Flood Prediction Dataset	20	FloodProbability	Excellent
3	Istanbul Apartment Prices 2026	29 or fewer*	Price	Good
4	Swiss Housing Price Prediction	30	House price	Good; restricted access

5	Human–AI Interaction	20	Trust score	Excellent; synthetic
6	House Prices — Advanced Regression	79 → select 20–30	SalePrice	Excellent for feature selection

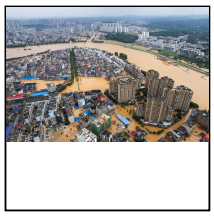
*Istanbul 資料集描述為 30 欄，包含價格等欄位；精確輸入特徵數需檢查 CSV。上述資料集的特徵數以來源描述為準，類別編碼後可能增加。

k

Kaggle

+5

My Top 3 for Teaching



1. Predict the Flood

20 numerical features, continuous target. Best for teaching OLS, MSE, R^2, residual analysis and regression assumptions.



2. Istanbul Apartment Prices

Suitable for categorical encoding, feature selection, and housing-price regression. Check the dataset columns before modeling.



3. Human–AI Interaction

20 original features, 10,100 samples. Useful for studying coefficients, categorical features and multicollinearity.

Suggested Assignment: CRISP-DM + Feature Selection

For any selected dataset, students can complete:

1. **Business Understanding:** Define the continuous prediction target.
2. **Data Understanding:** Verify sample size, feature count, missing values and correlations.
3. **Data Preparation:** Train/test split, missing-value handling and categorical encoding.
4. **Modeling:** Train `LinearRegression`, Ridge and Lasso.

5. **Evaluation:** Compare MAE, MSE, RMSE, R^2 and Adjusted R^2; check the five regression assumptions.
6. **Deployment:** Predict new samples and explain the model.

For Feature Selection, compare **SelectKBest, RFE, Sequential Feature Selection, Lasso and permutation importance**, selecting 14, 20, 25 or 30 features using training data only.

My first choice is Predict the Flood, because its 20 numerical features meet your constraint directly and avoid the extra complexity of categorical encoding.

檢視 / 修改我的作業

© Copyright since 2020 by National Chung Hsing University.
All rights reserved.
● 本站由 教學資源暨發展中心 管理●

線上： 2554 人